

AI Servo Platform — Scenarios 19–24

資料探勘、特徵工程與模型建立：完整分析報告

0. 摘要

本報告以 AI SERVO PLATFORM V5 Part 4 (情境 19–24) 之六份真實時序模擬資料為輸入，每一情境為一台設備從健康狀態運轉至故障 (trip) 之連續歷程，取樣間隔 $dt=0.001s$ ，每情境 15,000 筆，共 90,000 筆、121 個原始欄位。分析依序完成：(1) 資料探勘與 EDA、(2) 特徵工程 (因果 rolling 統計 + 情境專屬根因 proxy)、(3) 分類/回歸/分群三大模型動物園比較、(4) 超參數調校 (Optuna / GridSearch / 遺傳演算法)、(5) 深度學習與序列模型代理、(6) 白皮書導向的參數映射、通訊診斷與安全機制整理。

核心結論：

- fault_stage 五級分類 (normal/early_degradation/warning/alarm/trip) 在 20 個模型中最佳為 HistGradientBoosting，Weighted F1 = 0.9924；
- rul_sec 剩餘壽命回歸最佳為 ExtraTrees， $R^2 = 0.9997$ (注意：測試集為隨機切分而非留一情境，數值偏樂觀，詳見 §4 說明)；
- 10 種分群演算法中，Average-linkage 階層式分群 Silhouette 最高 (0.523)，但 DBSCAN/OPTICS 兩種密度分群法在此特徵空間找不到多群結構，顯示健康→故障為連續退化而非離散團簇；
- 虛擬感測回歸 (以其餘特徵預測 current_rms_a) R^2 接近 1.0，追蹤發現主要由 current_limit_pct 單一特徵近乎決定，屬模擬器內建的強確定性關係；
- 本環境未安裝 torch/tensorflow，故 RNN/LSTM/BiGRU+Attention 兩面板以「視窗展平特徵 + MLP」代理序列模型，並如實揭露此限制。

1. 資料來源與方法

1.1 資料來源

檔案	情境	設備	故障類型	樣本數
scenario_19_backlash.csv	19 Backlash	Bidirectional Index Table	機構間隙 (反向間隙)	15,000
scenario_20_high_vibration.csv	20 High Vibration	High Speed Scanner	振動/軸承劣化	15,000
scenario_21_power_supply_fluctuation.csv	21 Power Fluctuation	Multi Axis Start Station	電源/DC bus 漣波	15,000
scenario_22_voltage_drop.csv	22 Voltage Drop	Peak Load Acceleration Axis	負載中電壓驟降	15,000
scenario_23_communication_timeout.csv	23 Comm Timeout	PLC Sync Motion Axis	PLC 通訊逾時	15,000
scenario_24_ethercat_packet_loss.csv	24 EtherCAT Packet Loss	Distributed EtherCAT Axis	EtherCAT WKC/封包遺失	15,000

1.2 特徵工程

121 個原始欄位 → 依情境 (equipment run) 分組後，對 9 個關鍵通道 (電流、轉矩誤差、網路 jitter、EtherCAT 同步誤差、數位孿生位置殘差、振動 RMS、跟隨誤差、DC-bus 漣波、PLC 掃描時間) 計算因果 rolling(window=50) 平均/標準差/最大值；並依白皮書 §8 根因規則建立 7 個情境專屬交互作用 proxy (backlash_proxy、vibration_proxy、power_fluct_proxy、voltage_sag_proxy、comm_timeout_proxy、ethercat_proxy、jitter_roll_max)，新增 34 個工程特徵。扣除 health_index/anomaly_score/failure_probability/rul_cycle/warning-alarm-trip/maintenance_* 等標籤洩漏欄位後，得到 112 個可安全用於建模的特徵。

1.3 分析工具


scikit-learn 1.9、XGBoost 3.3、Optuna (TPE sampler)；深度學習面板因執行環境未安裝 torch/tensorflow，以 scikit-learn MLPClassifier/MLPRegressor 作為對照與代理，並於對應段落明確標註此限制。

2. 十五圖解詳細說明

以下對應 excalidraw_analysis_A3_2K_expert.pdf 之 15 個面板，逐一說明方法、產出數字與判讀。

圖 1. 初始訊號與大數據獲取架構

以情境 19 (Backlash) 與情境 20 (Vibration) 前 2,000 筆 vibration_rms_g 原始時序疊圖，展示真實感測雜訊的振幅差異。資料來源為 6 支情境 log，dt=0.001s，每情境 15,000 筆，共 90,000 筆 × 121 原始欄，涵蓋位置/速度/轉矩/電流/電壓/溫度/振動(XYZ+FFT+軸承)/網路(jitter/EtherCAT sync) 等感測類別。核心分析目標對應白皮書 §5.1：fault_stage 分類、rul_sec 回歸、根因診斷 → MR-J5 參數建議 (§6/§8)。



【感測數據源與採樣規格】

- 來源: scenarios_csv/scenario_19_24_*.csv (實測時序模擬)
- 採樣: dt=0.001s · 每情境 15,000 筆 → 共 90,000 筆 × 121 原始欄
- 感測類別: 位置/速度/轉矩/電流/電壓/溫度/振動(XYZ+FFT+軸承)/網路(jitter/EtherCAT)

【核心分析目標與輸出】

1. 預防保養 (PdM) : fault_stage 分類 (§5.1)
2. 剩餘壽命 RUL : rul_sec 回歸
3. 根因診斷 → MR-J5 參數建議 (§6/§8)

圖 1：情境 19/20 原始振動訊號疊圖與資料獲取規格說明

圖 2. 傳統分析法 (四大基石)

整理白皮書所依循的四類傳統工程分析方法，作為與後續 ML/DL 模型之基準對照：

- 經典統計與分解：describe() 全欄位統計、health_index / rul_sec 趨勢分解、rolling mean/std (w=50)
- 數位訊號處理 (DSP)：資料集既有 fft_1x_amp/fft_2x_amp、bearing_bpfo/bpfi/bsf/ftf_amp 等頻域特徵、resonance_amp 共振指標
- 控制系統與觀測分析：digital_twin_pos/speed/torque_residual 作為觀測器殘差、既有 gain_p/i/d、notch_filter_hz 控制參數
- 基礎統計與規則判斷：白皮書 §8 root-cause 規則 (following_error/vibration/thermal/comm 各項門檻)

2. 傳統分析法 (四大基石)




圖 2：四類傳統分析法對應白皮書章節與資料集既有欄位

圖 3. TOP 20 ML 分類模型 (fault_stage)

以 9,000 筆分層抽樣 (依 fault_stage 五級比例) 、 75/25 train/test 切分 , 比較 21 個 sklearn/XGBoost 分類器 + 1 個 Top-5 投票集成 (EnsembleStk) , 依 Weighted F1-Score 排序取前 20 :

排名	模型	Weighted F1
1	HistGradientBoosting	0.9924
2	RandomForest	0.9920
3	EnsembleStk (Top-5 投票)	0.9916
4	XGBoost	0.9907
5	GradientBoosting	0.9889
...	...	...
18	GaussianNB	0.8432

判讀 : 樹系集成模型 (HistGradientBoosting/RandomForest/XGBoost) 明顯領先線性模型 (RidgeClassifier 0.888 、 NearestCentroid 0.650) , 顯示 fault_stage 與感測特徵間存在非線性交互 , 需集成方法融合多通道訊號 。 BernoulliNB/NearestCentroid 未進入前 20 (原始 22 個模型中最弱 2 個已依使用者要求移除 , 僅列前 20) 。




圖 3 : 20 個分類模型 Weighted F1-Score 排序 (真實資料 , 非合成)

圖 4. TOP 20 ML 回歸模型 (rul_sec)

以 7,000 筆依情境分層抽樣、75/25 train/test 切分，比較 20 個回歸器對剩餘壽命秒數 (rul_sec) 之 R^2 ：

排名	模型	R^2
1	ExtraTrees	0.9997
2	HistGradientBoosting	0.9996
3	RandomForest	0.9995
4	BaggingRegressor	0.9995
5	GradientBoosting	0.9995
...	...	...
20	KNeighbors	0.9509

重要說明 (誠實揭露)：本面板採隨機 75/25 切分 (同一情境的相鄰時間點可能同時落入 train 與 test)，而非跨情境留一法 (LOSO)。由於每一情境是「單一連續退化歷程」，相鄰樣本高度相關，故此處 R^2 普遍 >0.95 屬於偏樂觀的「內插」表現，反映的是模型記憶單一軌跡形狀的能力，而非跨設備/跨故障類型的泛化能力。跨情境泛化的保守指標請見圖 14 (XGBoost LOSO 交叉驗證)。

4. TOP 20 ML 回歸模型 (rul_sec, real data)




圖 4：20 個回歸模型 R^2 排序 (rul_sec，隨機切分，非 LOSO)


圖 5. TOP 10 分群演算法效能

以 1,500 筆依情境分層抽樣、112 個標準化特徵，比較 11 種分群演算法之 Silhouette Score，取前 10（依使用者要求由 8 個擴充至 10 個，新增 BisectingKMeans、Agglomerative 平均連接/完全連接兩種變體）：

排名	演算法	Silhouette
1	Agglomerative (average linkage)	0.523
2	Agglomerative (complete linkage)	0.438
3	MeanShift	0.273
4	KMeans (k=5)	0.216
5	Birch	0.178
6	Agglomerative (ward, 預設)	0.178
7	MiniBatchKMeans	0.160
8	GaussianMixture	0.155
9	SpectralClustering	0.145
10	BisectingKMeans	0.081

重要發現：DBSCAN ($eps \times min_samples$ 網格搜尋 18 組參數) 與 OPTICS (預設參數) 在本特徵空間皆僅收斂出 0–1 群，因此未列入排名。這是有意義的負向結果——顯示六情境的健康→故障轉移為「連續退化」而非「離散團簇」，密度分群法不適用於此類資料，這與圖 2「健康度連續趨勢」的觀察一致，也支持圖 3/4 採用監督式 (有 *fault_stage/rul_sec* 標籤) 模型而非純分群的設計選擇。

5. TOP 10 分群演算法效能 (engineered features)



註：DBSCAN 於 $\text{eps} \times \text{min_samples}$ 網格搜尋、OPTICS 預設參數，於本特徵空間皆僅收斂出 0-1 群（密度連續、無明顯離群點），故未列入排名——顯示 6 情境的健康→故障轉移為連續退化而非離散團簇。

圖 5：10 個分群演算法 *Silhouette* 排序，並說明 DBSCAN/OPTICS 未收斂之原因

圖 6. 虛擬感測回歸分析 (*current_rms_a* 預測)

以其餘 111 個特徵（不含 *current_rms_a* 及其衍生 rolling 欄位）回歸預測 *current_rms_a*，比較 5 個線性/穩健迴歸模型：

模型	R ²	RMSE	MAE
BayesianRidge	1.0000	0.000003	0.000003
LinearRegression	1.0000	0.000003	0.000003
LinearSVR	1.0000	0.000013	0.000010
Ridge	0.9999	0.0033	0.0024
HuberRegressor	0.9999	0.0035	0.0025

核心提取特徵 (*BayesianRidge* |係數| 排序)： *current_limit_pct* 以壓倒性權重 (0.596) 主導預測，其後

依序為 *actual_pos_pulse*、*encoder_count*、*encoder_count_interpolated*、*bearing_bpfo_amp* (皆 <0.005) 。判讀： $R^2 \approx 1.0$ 並非模型能力特別突出，而是揭露了模擬資料集中 *current_rms_a* 與 *current_limit_pct* 存在近乎確定性的內建關係——此為誠實的資料集特性說明，而非過度宣稱的建模成果。

6. 虛擬感測回歸分析 (*current_rms_a* 預測)

model	R ²	RMSE	MAE
BayesianRidge	1.0	0.0	0.0
LinearRegress	1.0	0.0	0.0
LinearSVR	1.0	0.0	0.0
Ridge	1.0	0.0033	0.0024
HuberRegress	1.0	0.0035	0.0025

核心提取特徵 (Top-5 |coef|, BayesianRidge)




圖 6：虛擬電流感測器回歸模型比較表與核心特徵權重

圖 7. ML 參數粗調 (Optuna)

以 Optuna TPESampler 對 XGBoost 分類器 (fault_stage) 進行 18 次貝葉斯搜尋，搜尋空間涵蓋 $n_estimators \in [50, 300]$ 、 $max_depth \in [3, 10]$ 、 $learning_rate \in [0.02, 0.3]$ (對數尺度)、 $subsample \in [0.6, 1.0]$ ，每次試驗以 3-fold StratifiedKFold CV Weighted-F1 為目標函數。最優參數： $n_estimators=137$ 、 $max_depth=8$ 、 $learning_rate=0.171$ 、 $subsample=0.885$ ，CV F1=0.9898。曲線顯示搜尋於約第 10 次試驗後即逼近最優，之後僅有微幅改善，反映搜尋空間對此資料集已相對平坦 (多組參數皆可達到 >0.98 的高分)。




圖 7 : Optuna 18 次試驗之 best-so-far F1 曲線與最優參數

圖 8. ML 局部搜尋 (GridSearch)

針對 RandomForest 分類器，於 $\text{max_depth} \in \{4, 8, 12, 16\} \times \text{n_estimators} \in \{50, 100, 200\}$ 共 12 組網格，以 3-fold CV Weighted-F1 熱力圖呈現。結果顯示 max_depth 是主導因子 ($\text{depth}=16$ 各列 CV-F1 皆 >0.99)， n_estimators 在此範圍內影響有限 (同一 depth 列內差異 <0.002)，顯示樹深度比樹的數量對此資料集更關鍵——與圖 3 中樹系模型全面領先線性模型的結論一致 (非線性交互需要足夠深度捕捉)。




圖 8 : RandomForest $\text{max_depth} \times \text{n_estimators}$ GridSearch CV-F1 熱力圖

圖 9. ML 遺傳進化調參 (GA)

自製簡易遺傳演算法 (無外部套件依賴) · 族群大小 8 · 演化 5 代 · 基因編碼 $[n_estimators, max_depth, learning_rate]$ (正規化至 $[0,1]$ 再解碼) · 採均勻交叉 + 高斯突變 ($\sigma=0.08$) · 適應度函數與圖 7 相同 (3-fold CV Weighted-F1 · XGBoost) · 因未實作菁英保留 (elitism) · 族群最佳值 (population-best, 虛線) 第 1 代即達到最高點 0.9898 後隨機微幅波動; best-so-far (實線) 維持在初代最優值。此為隨機搜尋在小族群/少代數下的正常現象, 也印證圖 7 Optuna 的結論——此資料集的最優參數區域範圍寬廣、多種搜尋策略皆能快速逼近。




圖 9: 遺傳演算法 5 代族群最佳與 best-so-far CV-F1 曲線

圖 10. DL 神經網絡分析 (MLP)

以 scikit-learn MLPClassifier (隱藏層 $64 \rightarrow 32 \rightarrow 16$, 共 112 維輸入、5 類輸出) 訓練 fault_stage 分類器 , 最多迭代 250 次、實際收斂於 70 個 epoch (loss 由初始約 1.5 降至 0.0012) 。測試集 Weighted F1 = 0.9773 , 優於多數傳統線性模型但略遜於圖 3 中樹系集成模型 (HistGBoost 0.9924) , 顯示在本資料規模 (9,000 筆訓練) 下 , 全連接深度網路尚未展現優於樹模型的優勢 , 此結論與白皮書 §9 建議之集成樹方法 (XGBoost/LightGBM) 相符。





圖 10 : MLP 分類器 Cross-Entropy Loss 收斂曲線 (70 epochs)

圖 11. RNN/LSTM 時序分析 (架構示意)

本面板為 LSTM 遺忘門/輸入門/輸出門三閘門架構示意圖。重要限制揭露：執行環境未安裝 torch/tensorflow，故無法訓練真正的 LSTM/GRU 序列模型。以「視窗特徵展平 + MLP」作為代理方案——對 6 個關鍵感測通道 (following_error_abs_pulse、vibration_rms_g、current_rms_a、motor_temp_c、network_jitter_ms、ethernet_sync_error_us) 取長度 L=15 的歷史視窗 (90 維)，訓練 MLPClassifier 預測 fault_stage，測試集 Weighted F1 = 0.8912。此分數低於圖 3/10 之全特徵模型，符合預期——因僅用 6 通道原始訊號 (未含 112 維工程特徵)，用以單純評估「序列窗口資訊本身」的判別力。

11. RNN/LSTM 時序分析 (架構示意)

【LSTM 時序雙存單元】



torch/tensorflow 未安裝於本環境 → 以「視窗特徵展平 + MLP」作為序列模型代理
(視窗長度 L=15 · 6 感測通道 × 15 步 = 90 維)
測試集 Weighted F1 = 0.8912 (見面板12逐步注意力剖繪)

圖 11：LSTM 閘門架構示意，並說明序列代理模型之限制與結果

圖 12. 雙向 GRU + Attention 機制 (線性探針權重代理)

延續圖 11 之限制，本面板以邏輯回歸線性探針之 |係數| 在 $L=15$ 視窗各步位置的平均值，作為「偽注意力權重」(pseudo-attention) 之代理，藉此觀察何時間步對分類貢獻最大。結果顯示權重分布相對平坦（範圍 0.058–0.081），峰值出現在 $t=-4$ （而非直覺預期的最近步 $t=-1$ ），顯示以簡單線性探針觀察到的訊號重要性分散於整個視窗，並未集中在單一時間步。誠實聲明：此結果僅為簡化代理，與真正 BiGRU+Attention（需要 torch 訓練雙向循環網路與可學習的注意力層）在數值上不能直接類比。

12. 雙向 GRU + Attention 機制 (線性探針權重代理)




圖 12：線性探針偽注意力權重於 15 步視窗之分布熱圖

圖 13. 參數物理映射與匯流排防護機制

依白皮書 §6 三菱參數矩陣與 §8 根因規則，整理本資料集之感測特徵與 MR-J5 參數建議之對應關係，並重申 §11 安全寫入原則：

- 遙測特徵 → MR-J5 參數：following_error_abs_pulse → Position/Speed loop gain；vibration_rms_g + bearing_bpfo/bpfi_amp → Notch filter / Vibration suppression
- 電源/電流特徵 → 保護參數：current_rms_a + dc_bus_ripple_v → Torque limit、Current filter；motor/drive_temp_c → Accel/Decel、Duty cycle 降載
- 通訊特徵 → 網路防護 (§8.5)：network_jitter_ms、ethercat_sync_error_us → 優先修正 PLC cycle / EtherCAT sync，而非直接調整 servo gain
- 安全寫入與回滾機制 (§11)：Backup-first (寫入前備份參數 checksum)、低速 Dry-run 試跑驗證、KPI 劣化時自動 Rollback

13. 參數物理映射與匯流排防護機制



圖 13：感測特徵→MR-J5 參數對應表與白皮書安全寫入原則

圖 14. 傳統方法 vs ML vs DL 綜合評測

以三組代表模型比較分類 (F1) 與回歸 (R^2) 表現：「傳統/簡易法」取分類動物園中最弱的 NearestCentroid (F1=0.650) 與回歸動物園中的 KNeighbors ($R^2=0.951$) 作為簡易基準；「機器學習」取圖 3/4 之最佳樹系模型 (HistGBoost F1=0.992、ExtraTrees $R^2=1.00$) ；「深度學習」取圖 10 MLP (F1=0.977) 與回歸動物園中的 MLPRegressor ($R^2=0.999$) 。三組比較顯示 ML 與 DL 皆大幅超越簡易基準，且在本資料規模下樹系集成 ML 些微領先 DL，與白皮書 §9 建議之模型選型結論一致。




圖 14：傳統/ML/DL 三組代表模型之分類 F1 與回歸 R^2 綜合比較

圖 15. 通訊異常診斷流程 (情境 23/24 , 白皮書§8.5)

以情境 23 (Communication Timeout) 之真實資料統計各 fault_stage 下的關鍵通訊指標，佐證白皮書 §8.5 「先修網路，不先調 servo gain」之診斷順序：

fault_stage	network_jitter_ms (均值)	ethercat_sync_error_us	plc_scan_time_ms
normal	0.10	4.01	2.00
early_degradation	0.59	4.01	2.59
warning	2.79	4.01	5.23
alarm	5.72	3.97	8.74
trip	8.63	4.02	12.23

判讀：network_jitter_ms 與 plc_scan_time_ms 隨故障階段單調上升 (trip 為 normal 的約 86 倍/6 倍)，是通訊劣化的主要指標；ethercat_sync_error_us 在此情境中變化不大 (因該指標主要對應情境 24 EtherCAT 封包遺失，而非情境 23 PLC 逾時)，顯示不同通訊故障類型需搭配對應的關鍵指標判讀，不可一概而論。流程步驟依白皮書§8.5 與§11 排列：監測→檢查→先修網路 (不調 servo) →確認 PLC 穩定→封包錯誤歸零後才進行 servo tuning→通過後才允許 EEPROM 永久寫入。

15. 通訊異常診斷流程 (情境23/24, 白皮書§8.5)



圖 15：情境 23 通訊指標隨故障階段變化統計與診斷流程步驟

3. 限制與後續建議

- 深度學習序列模型 (LSTM/GRU/Attention) 因環境限制以 MLP 代理，正式導入建議安裝 torch/tensorflow 並以完整序列模型 (含真正的雙向循環與可學習注意力層) 重新訓練圖 11/12。
- 圖 4 回歸 R^2 採隨機切分而非跨情境留一法 (LOSO)，數值偏樂觀；跨情境泛化的保守評估請參考圖 14 及先前 excalidraw_analysis_A3_2K_expert_updated.pdf 之 LOSO 交叉驗證結果 (分類平均準確率 0.934、F1-macro 0.937；回歸平均 R^2 0.994，同樣因單一連續退化軌跡而偏高，請以此為方法論驗證而非直接產線部署依據)。
- 圖 6 虛擬感測器回歸之近乎完美 R^2 反映模擬器內建確定性關係，實際產線之感測器互相預測關係應顯著更弱，正式導入需以真實產線資料重新驗證。
- 白皮書安全原則：AI 僅提出建議、風險等級與驗證方法；任何 MR-J5 參數實際寫入，必須由授權工程師確認，並依§11 流程執行 backup-first、低速 dry-run、KPI 比對與自動 rollback。

— 報告完 —